

DART BIG:IN

공시 신호 워드클라우드 Scoring Logic

현재 Production 계산 과정 · 가중치 · 벌점 수식 · 설계 이유 정리

문서 상태 현재 대화에서 실제 production 반영이 확인된 로직과, 아직 실험/진단 단계인 로직을 명확히 구분한다. 이후 scoring 체계가 변경되면 이 문서도 함께 갱신해야 한다.

0. 전체 계산 흐름

1	2	3	4	5	6	7	8
Corpus 선택	후보 생성·정제	연도별 언급비중	Current / Change / Spread	기본 Signal Score	기업 집중도 벌점	최종 점수	Top 12 표시

핵심 원칙 점수는 “많이 언급되는 단어”만 고르는 것이 아니라, 현재 중요도·최근 변화·여러 기업으로의 확산을 함께 보도록 설계되어 있다. 이후 특정 기업 한 곳에 언급이 쏠리는 경우에는 별도 벌점으로 산업 대표성을 보정한다.

1. 분석 대상 Corpus

- 대상 기업: 선택된 KRX 섹터/지수의 대표 Top5 기업
- 기간: 2023~2025년
- 보고서: Q1 / H1 / Q3 / FY 정기공시
- 공시 조건: is_active = 1, is_searchable = 1
- 주요 section: II. 사업의 내용, IV. 이사의 경영진단 및 분석의견, 연구개발실적 관련 상세표
- ‘기타 참고사항’은 제외하지 않는다. HBM 등 실제로 유효한 산업 키워드가 이 section에 다수 포함되어 있음을 DB로 확인했기 때문이다.

왜 section 전체 삭제를 피하는가? “기타 참고사항”에는 ESG·법률성 표현도 섞여 있지만, HBM처럼 중요한 산업 정보도 함께 들어 있었다. 따라서 section을 통째로 제거하는 대신 후보 품질 필터와 공통 노이즈 필터로 정제하는 방식이 더 안전하다.

2. 후보 생성 및 정규화

- Unicode NFKC 정규화, 연속 공백 축약
- alias 정규화: 고대역폭 메모리 / HBM3 / HBM3E / HBM4 → HBM, AI서버 / AI 서버 → AI 서버

유형	생성 방식	예시
사전 복합어	정규식으로 먼저 감지	AI 서버, AI 수요, HBM 수요, 첨단 패키징, 설비 투자, 생산 능력
영문 기술어/약어	정규식 또는 Kiwi SL 대문자 토큰	HBM, DRAM, NAND, SSD, GDDR, HPC, CXL
한글 단일어	Kiwi NNG/NNP 중 허용 목록	파운드리, 메모리, 웨이퍼, 패키징
한글 복합어	인접한 명사 토큰 2개 결합	데이터 센터, 수주 상황, AI 기반

3. 후보 필터링

- 공통 기본 필터: **stopword**, 분석 대상 기업명, 숫자·기호만인 값, 너무 짧은 토큰, 표·규격 토큰(mm, nm, Glass, Size, Type, Model 등) 제거
- 섹터 헤더성·저정보 표현 및 **context-free** 구성요소 제거. 구체 복합어가 존재하면 단독 일반어를 제거할 수 있음.
- 최신연도 최소 등장 조건: `count_2025 >= 2`
- 산업 확산 최소조건: 최신연도 `company_count >= 2`
- 섹터 공통 **hard-noise** 필터: 통화/환율, 기간 비교, 회계·보고서 관용 표현 제외
- 홍보·수식, 일반 경영 표현은 현재 **production**에서 자동 제거하지 않음

company_count >= 2의 이유 초기에는 최종 후보 5,786개 중 5,090개가 2025년에 한 기업에서만 등장했다. 산업 위드클라우드의 목적은 “대표기업 전체에서 관찰되는 산업 신호”이므로, 최소 2개 기업에서 확인되는 키워드만 **scoring**에 진입시키도록 했다. 단, 3개 이상으로 올리면 CXL·PECVD처럼 산업적으로 의미 있는 2개 기업 공통 신호까지 잃을 수 있어 최소 기준은 2개로 유지했다.

현재 **KRX_SEMI** 후보 수 변화 5,786개 → `company_count >= 2` 적용 후 696개 → 공통 **hard-noise** 필터 후 650개

4. 연도별 언급비중 계산

- 한 chunk 안에서 같은 키워드가 여러 번 등장해도 그 chunk에서는 1회만 집계한다.

연도별 언급비중

$$S_y = (\text{해당 연도에서 키워드가 등장한 chunk 수}) / (\text{해당 연도의 전체 eligible chunk 수})$$

Raw 빈도 대신 chunk 비중을 사용해 보고서 길이·반복 횟수 차이의 영향을 일부 줄인다.

- Current는 최신연도인 2025년만 사용하고, 2023·2024년은 변화 계산에 사용한다.

5. 세 가지 기본 점수

측	Raw 값	0~100 변환	현재 가중치	의미
Current	CurrentRaw = S25	최종 scoring 후보군 내 percentile rank	50%	지금 얼마나 중요하게 언급되는가
Change	$0.4 \times (S24 - S23) + 0.6 \times (S25 - S24)$	최종 scoring 후보군 내 percentile rank	30%	최근 3년 동안 얼마나 부상했는가
Spread	company_count	$company_count / 5 \times 100$	20%	Top5 중 몇 기업에 퍼져 있는가

5.1 Current Score — 50%

$$\text{CurrentRaw} = S25$$

- 가중치 50%로 가장 크게 둔 이유: 워드클라우드의 기본 목적은 “현재 공시에서 중요한 키워드”를 보여주는 것이기 때문이다.
- 변화량만 크게 반영하면 오래전부터 핵심인 HBM·메모리 같은 단어가 최근 증가폭이 작다는 이유로 지나치게 작아질 수 있다.
- 따라서 안정적으로 중요한 핵심 용어가 유지되도록 Current를 가장 높은 50%로 둔다.

percentile을 쓰는 이유와 한계 처음에는 섹터마다 키워드 빈도 분포가 다르기 때문에 “언급비중 5%면 몇 점” 같은 임의의 절대 기준을 피하려고 percentile rank를 채택했다. 다만 후보 수가 많을 때 상위권 점수가 서로 매우 가까워지는 문제가 확인되었다. 현재 production은 percentile을 유지하고 있지만, ranking score와 visual size를 분리하거나 normalization을 재검토해야 하는 과제가 남아 있다.

5.2 Change Score — 30%

$$\text{ChangeRaw} = 0.4 \times (S24 - S23) + 0.6 \times (S25 - S24)$$

- 0.4 / 0.6을 사용한 이유: 최근 변화에 조금 더 높은 비중을 주되, 3년 흐름을 완전히 버리지 않기 위해서다.
- 0.5 / 0.5를 쓰면 수식상 중간연도(S24)의 영향이 상쇄되는 문제가 있어, 2024년의 경로 정보가 남도록 비대칭 가중치를 사용했다.
- 변화율(%)이 아니라 percentage-point 차이를 사용한다. 아주 작은 기저에서 비율 증가율이 폭발하는 현상을 피하기 위해서다.
- Change는 Current보다 낮은 30%로 둔다. “최근 급등”만으로 핵심 키워드를 압도하지 않게 하기 위함이다.

5.3 Spread Score — 20%

SpreadScore

$$\text{SpreadScore} = (\text{company_count} / 5) \times 100$$

1개	2개	3개	4개	5개
20	40	60	80	100

- 선형 점수를 사용하는 이유: Top5 표본에서는 기업 수 자체가 작고 해석이 직관적이기 때문이다.
- Spread를 20%로 둔 이유: 산업 공통성은 중요하지만, 기업별 사업 구조가 달라 같은 산업 변화가 서로 다른 방식으로 나타날 수 있으므로 Current·Change보다 보조적으로 사용한다.

Spread와 company_count >= 2의 차이 company_count >= 2는 “scoring 후보 진입을 위한 최소 조건”이고, SpreadScore는 그 이후 2·3·4·5개 기업으로 퍼진 정도를 점수에 반영하는 별도 축이다.

6. 기본 Signal Score

기본 점수

$$\text{SignalScore} = 0.50 \times \text{CurrentScore} + 0.30 \times \text{ChangeScore} + 0.20 \times \text{SpreadScore}$$

가중치의 해석 50/30/20은 “현재 중요성 > 최근 변화 > 기업 확산” 순서의 우선순위를 수치화한 것이다. 장기 핵심 키워드는 유지하고, 새롭게 부상하는 키워드는 가산하며, 한두 기업에만 국한되는 용어는 확산도에서 불리하게 만든다.

7. 기업 집중도 보정

- company_count >= 2만으로는 실제 언급이 한 기업에 90% 이상 몰린 키워드를 충분히 걸러내지 못했다.

기업 집중도

$$\text{max_company_share} = (2025\text{년에 가장 많이 언급한 기업의 chunk_count}) / \text{count_2025}$$

연속형 집중도 벌점

$$\text{ConcentrationPenalty} = \min(15, \max(0, (\text{max_company_share} - 0.50) \times 30))$$

집중도 보정 점수

$$\text{ConcentrationAdjustedScore} = \text{SignalScore} - \text{ConcentrationPenalty}$$

최대 기업 비중	벌점	해석
50% 이하	0점	특정 기업 쏠림으로 보지 않음
60%	약 3점	약한 집중
70%	약 6점	중간 집중
80%	약 9점	높은 집중
90%	약 12점	매우 높은 집중
100%	15점(상한)	사실상 한 기업 중심

- 50%를 기준점으로 잡은 이유: Top5 중 최소 2개 이상 기업에 분산되어 있다면 한 기업이 절반 이하를 차지하는 상태는 과도한 집중으로 보지 않기 위해서다.
- 기울기 30을 사용하면 10%p 집중도 증가마다 약 3점씩 감점된다. 계단형보다 경계값 점프가 없어 연속적이다.
- 최대 15점 cap을 둔 이유: 집중도는 “산업 대표성 보정”일 뿐, Current/Change/Spread로 형성된 기본 중요도를 완전히 지워버리지 않도록 하기 위해서다.

실제 효과 예시 FHD·AMOLED·OS·HD는 company_count=2였지만 삼성전자 비중이 약 92~96%로 확인되어 큰 감점을 받고 Top12 밖으로 내려갔다. 반면 HBM(약 41%), 웨이퍼(약 39%), PECVD(약 52%)는 비교적 분산되어 순위가 유지되거나 상승했다.

8. 공통 노이즈 처리와 일반 경영 penalty

- Production hard filter: 통화/환율, 기간 비교, 회계·보고서 관용 표현은 scoring 전에 제거한다.
- 예: JPY, 전년 동기, 동기 대비, 당기 매출액 등
- 홍보·수식 표현은 자동 제거하거나 감점하지 않고 진단 표시만 유지한다.
- 일반 경영 표현은 완전 제거하지 않고 2점의 약한 감점만 적용한다. 산업적으로 의미가 있을 수 있는 범용 표현을 살리면서, 제품·기술·수요 키워드보다 과도하게 상위에 오르는 현상을 완화하기 위한 보정이다.

일반 경영 감점

$$\text{GenericBusinessPenalty} = 2 \text{ if } \text{generic_business} = \text{True}, \text{ else } 0$$

최종 Production 점수

$$\text{FinalSignalScore} = \text{SignalScore} - \text{ConcentrationPenalty} - \text{GenericBusinessPenalty}$$

- 2점으로 제한한 이유: 일반 경영 표현은 반드시 노이즈라고 볼 수 없으므로 강하게 제거하지 않는다. 실제 비교 실험에서도 Top12 구성은 유지되고 순위만 완만하게 조정됐다.
- 섹터 공통 규칙으로 적용한다. 반도체 특정 단어를 겨냥한 하드코딩이 아니라, 모든 섹터에서 동일한 일반 경영 범주 판정에 같은 감점을 적용한다.

실제 효과 KRX_SEMI에서 수주 상황은 91.59점에서 2점 감점되어 최종 89.59점으로 1위→2위, 부가 가치는 85.61점에서 83.61점으로 8위→10위가 됐다. Top12 구성 자체는 바뀌지 않아 보정 강도가 과하지 않은 것으로 확인했다.

8.1 최신 Production Top12 예시 — KRX_SEMI

순위	키워드	Signal	집중도 감점	일반 경영 감점	Final
1	SSD	91.31	0.61	0	90.70
2	수주 상황	91.59	0.00	2	89.59
3	데이터 센터	90.16	1.06	0	89.10
4	HBM	88.48	0.00	0	88.48
5	웨이퍼	88.37	0.00	0	88.37
6	OLED	88.16	0.20	0	87.96
7	GDDR	86.86	0.83	0	86.03
8	PECVD	85.40	0.58	0	84.83
9	생산 능력	84.45	0.00	0	84.45
10	부가 가치	85.61	0.00	2	83.61
11	가동 시간	82.64	0.00	0	82.64
12	평균 가동	82.04	0.00	0	82.04

해석 주의 이 Top12는 현재 확정된 production 계산 로직의 결과 예시다. 다만 “산업분석에 적합한 대표 키워드인가”라는 의미 품질과, Top12 간 점수 차이가 작아 워드클라우드 글자 크기가 비슷해지는 문제는 다음 개선 단계로 남아 있다.

9. 🔥 부상 키워드 판정

현재 판정 규칙

is_hot = (ChangeScore가 전체 후보 상위 10%) AND (ChangeRaw > 0)

- 🔥는 FinalSignalScore와 별개다. 큰 글자는 “현재 종합적으로 중요”, 🔥는 “최근 상승 속도가 빠름”을 뜻한다.
- ChangeRaw > 0 조건을 추가한 이유: 전체 변화가 부정적이어도 상대적으로 덜 감소한 단어가 상위 10%에 들어가 🔥가 붙는 오류를 막기 위해서다.
- 🔥는 전체 scoring 후보에서 계산하지만, 실제 화면에는 최종 Top12에 포함된 키워드에만 표시한다.

10. 최종 표시 규칙

- 최종 워드클라우드 표시 개수: Top 12
- 정렬 기준: FinalSignalScore 내림차순
- Top12 밖의 키워드는 scoring 결과에 남지만 화면 payload에는 포함되지 않는다.
- 현재 워드클라우드 글자 크기도 FinalSignalScore를 사용 중이다.

현재 남은 시각화 문제 Top12의 FinalSignalScore 차이가 크지 않아 글자 크기가 비슷하게 보일 수 있다. 따라서 다음 단계에서는 “Top12를 뽑는 Ranking Score”와 “화면 글자 크기를 결정하는 Visual Weight”를 분리하는 것이 유력한 개선 방향이다.

11. Production / 실험 상태 구분

항목	현재 상태	비고
Current/Change percentile	Production	상위권 점수 압축 문제는 남아 있음
가중치 50/30/20	Production	Current > Change > Spread 우선순위
company_count >= 2	Production	산업 확산 최소조건
공통 hard-noise filter	Production	통화/환율·기간 비교·회계 관용 표현 제거
연속형 concentration penalty	Production	최대 15점 감점
Top12	Production	집중도 + 일반 경영 감점이 반영된 FinalSignalScore 기준
🔥 상위 10% + 양(+의 변화	Production	Top12 안에서만 표시
일반 경영 -2점	Production	일반 경영 태그에 약한 감점; 홍보·수식은 감점 없음
P99/P95 raw-magnitude normalization	미채택	상위 점수가 100에 몰리는 문제 발생
Robust min-max / 대체 normalization	미확정	다음 단계 검토 대상
Sector Specificity	아이디어 단계	다른 섹터와 비교하는 TF-IDF 유사 접근
Ranking Score / Visual Weight 분리	미반영	글자 크기 차이 문제 해결 후보

12. 설계 의도 요약

설계 요소	왜 이렇게 했는가
50% Current	오래된 핵심 산업 용어가 “최근 증가하지 않았다”는 이유만으로 사라지지 않게 한다.
30% Change	최근 부상하는 용어를 올리되, 신규성 하나가 전체 순위를 지배하지 않게 한다.
20% Spread	여러 대표기업에 걸쳐 나타나는 산업 신호를 선호하되, 기업별 사업 차이를 허용한다.
company_count >= 2	한 회사 전용 표현이 산업 워드클라우드 후보가 되는 것을 막는 최소 안전장치다.
집중도 벌점	2개 이상 기업에서 등장하더라도 실제 언급량이 한 회사에 몰린 경우 산업 대표성을 낮춰 반영한다.
일반 경영 -2점	산업적으로 의미가 있을 수 있는 범용 경영 표현은 제거하지 않고 소폭만 감점해 과도한 상위 노출을 완화한다.
Top12	초보자 화면에서 정보 과밀을 피하고 핵심 신호만 보이게 한다.
 별도 표시	“중요한 단어”와 “최근 빠르게 부상하는 단어”를 같은 점수 하나로 섞지 않는다.

13. 현재 남은 핵심 과제

- Percentile normalization을 계속 사용할지 재검토: 상위권 점수 간 거리가 실제 raw 차이보다 압축될 수 있다.
- Top12의 의미 품질 개선: 수주 상황, 부가 가치, 가동 시간, 평균 가동처럼 범용적인 표현을 산업 대표 키워드로 볼지 추가 검토가 필요하다.
- Ranking Score와 Visual Weight 분리: 순위는 현재 점수체계를 사용하더라도 글자 크기는 Top12 내부에서 별도 스케일링할 수 있다.
- Sector Specificity 검토: 여러 섹터에서 흔한 표현보다 해당 섹터를 특징짓는 용어를 높이는 TF-IDF 유사 축을 추가할지 검토한다.
- 최종 로직 확정 후 실험/진단/비교용 코드 정리 및 공통 로직과 SectorVocabulary/config 분리 리팩터링.

한 줄 요약 현재 production은 “현재 중요도 50% + 최근 변화 30% + 기업 확산도 20%”로 기본 점수를 만들고, 특정 기업 쏠림에 대한 연속형 집중도 벌점과 일반 경영 표현 2점 벌점을 차감한 FinalSignalScore로 순위를 정한다. 상위 12개만 표시하며, 는 별도의 최근 상승 신호다.